

INTERPRETACION DE MODELOS

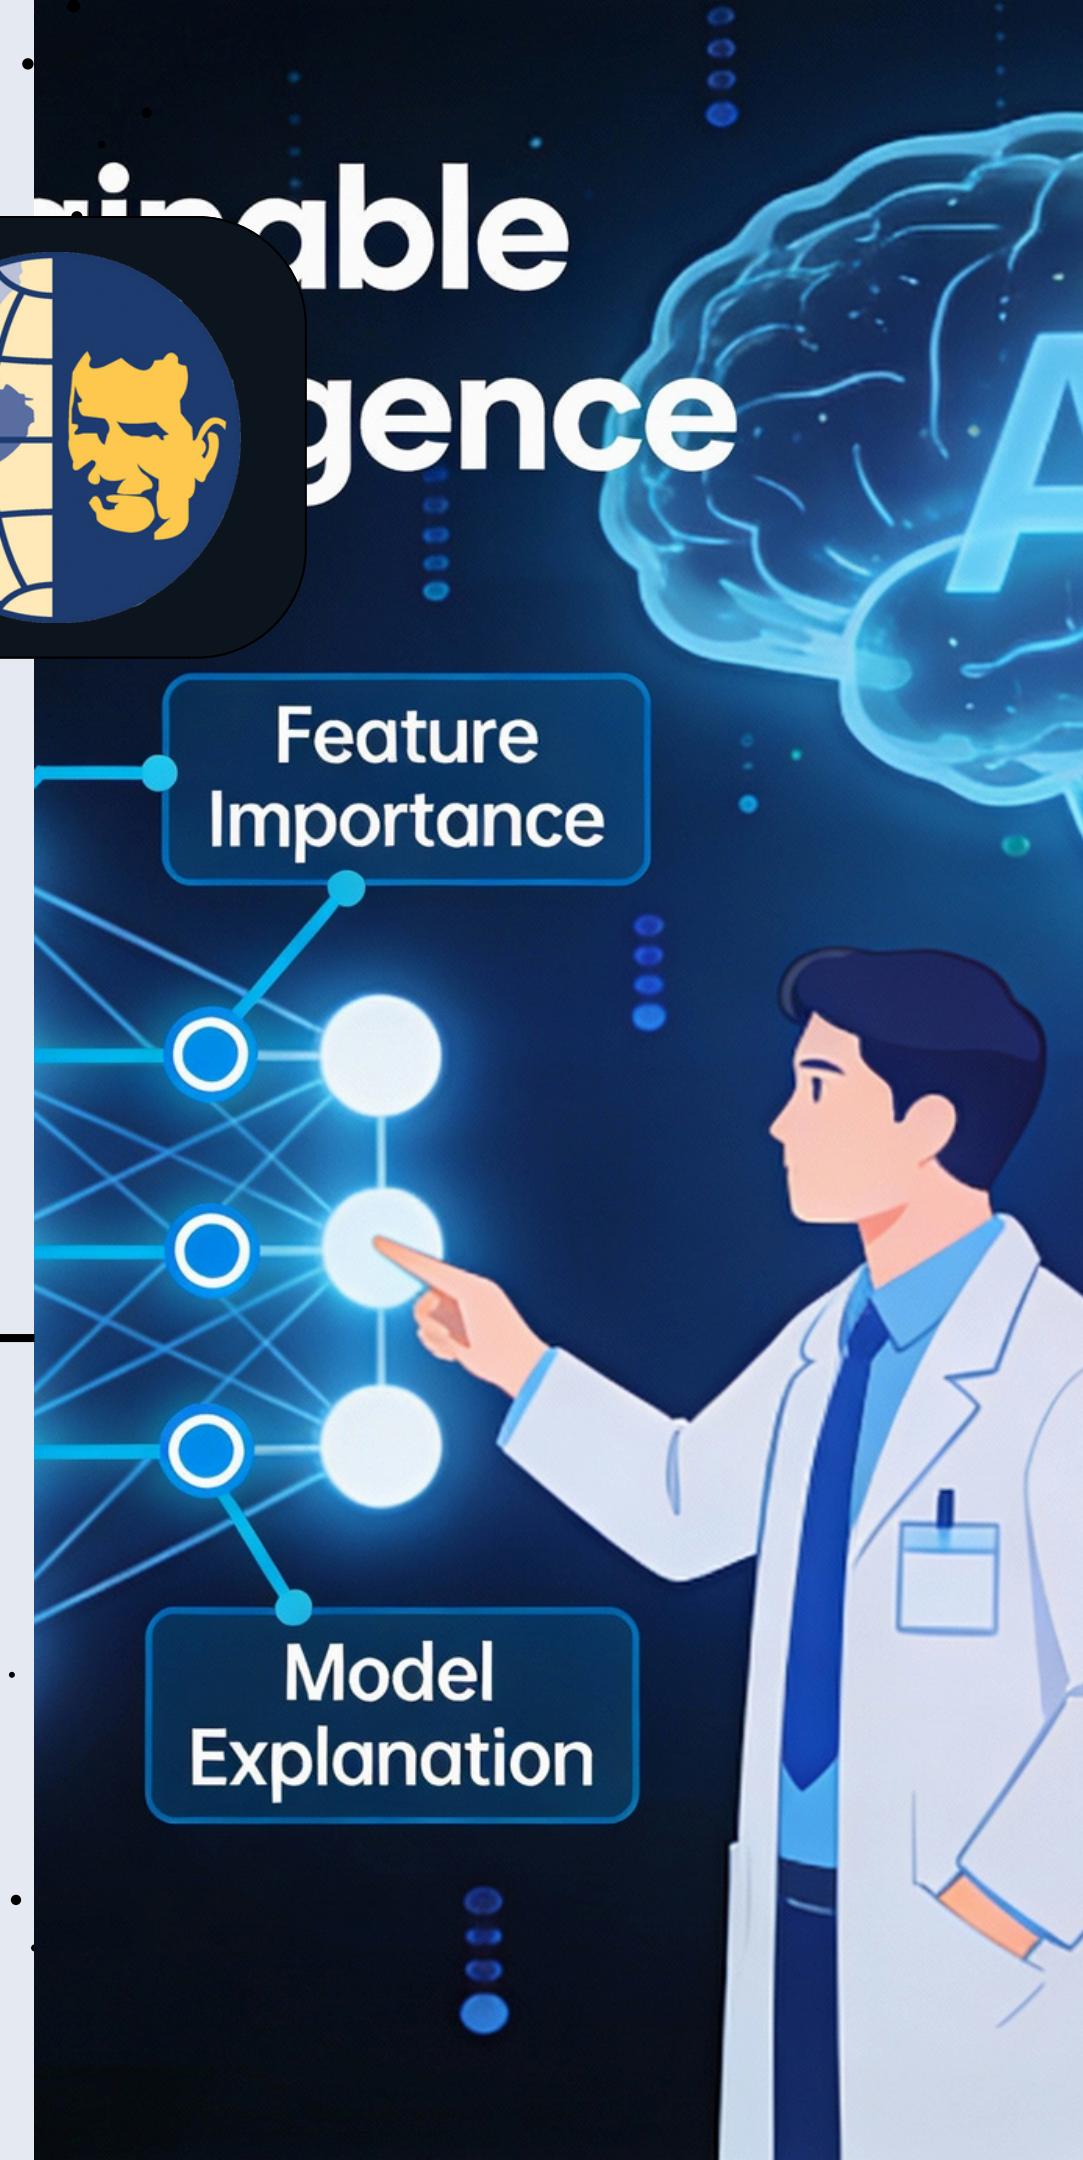
XAI (Explainable Artificial Intelligence)

Random Forest y Red Neuronal & SVM y CNN

David Uzhca

Domenika Delgado

Irar Nankamai





Random Forest

y

Red Neuronal



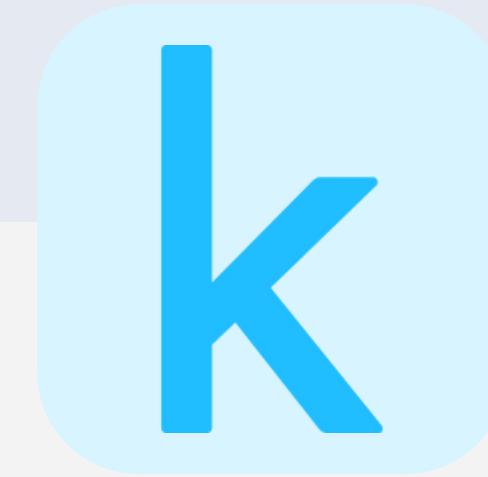
DATASET

Online Shoppers Purchasing
Intention Dataset
(datos estructurados)

SVM

y

CNN



Oxford-IIIT Pet Dataset
(clasificación de imágenes)



Online Shoppers Purchasing
Intention Dataset
(datos estructurados)

Random Forest y Red Neuronal

Predecir si un usuario finalizará o no **una compra** (Revenue) a partir de su comportamiento de navegación en un sitio web de comercio electrónico.

- Variables numéricas y Variables categóricas
- Variable objetivo: **Revenue** (0 = no compra, 1 = compra).



Random Forest

y

Red Neuronal



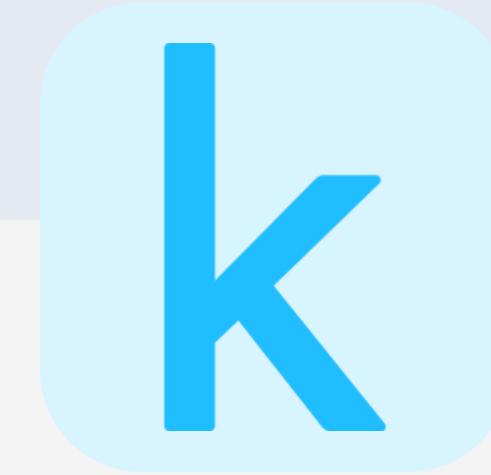
DATASET

Online Shoppers Purchasing
Intention Dataset
(datos estructurados)

SVM

y

CNN



Oxford-IIIT Pet Dataset
(clasificación de imágenes)



SVM
y
CNN

Oxford-IIIT Pet Dataset (clasificación de imágenes)

Clasificar imágenes de **mascotas** (perros y gatos) utilizando modelos clásicos de visión por computador y modelos de Deep Learning.

- Imágenes RGB de distintas razas.
- Variabilidad en tamaño, pose, iluminación y fondo.
- Etiquetas balanceadas entre clases.



Modelos utilizados

Random Forest

Ensamble de árboles de decisión

Capaz de **capturar relaciones** no
lineales

Proporciona medidas directas de
importancia de variables

Red Neuronal Artificial (MLP)

Modelo **no lineal** de múltiples
capas

Alta capacidad de representación

Menor interpretabilidad directa

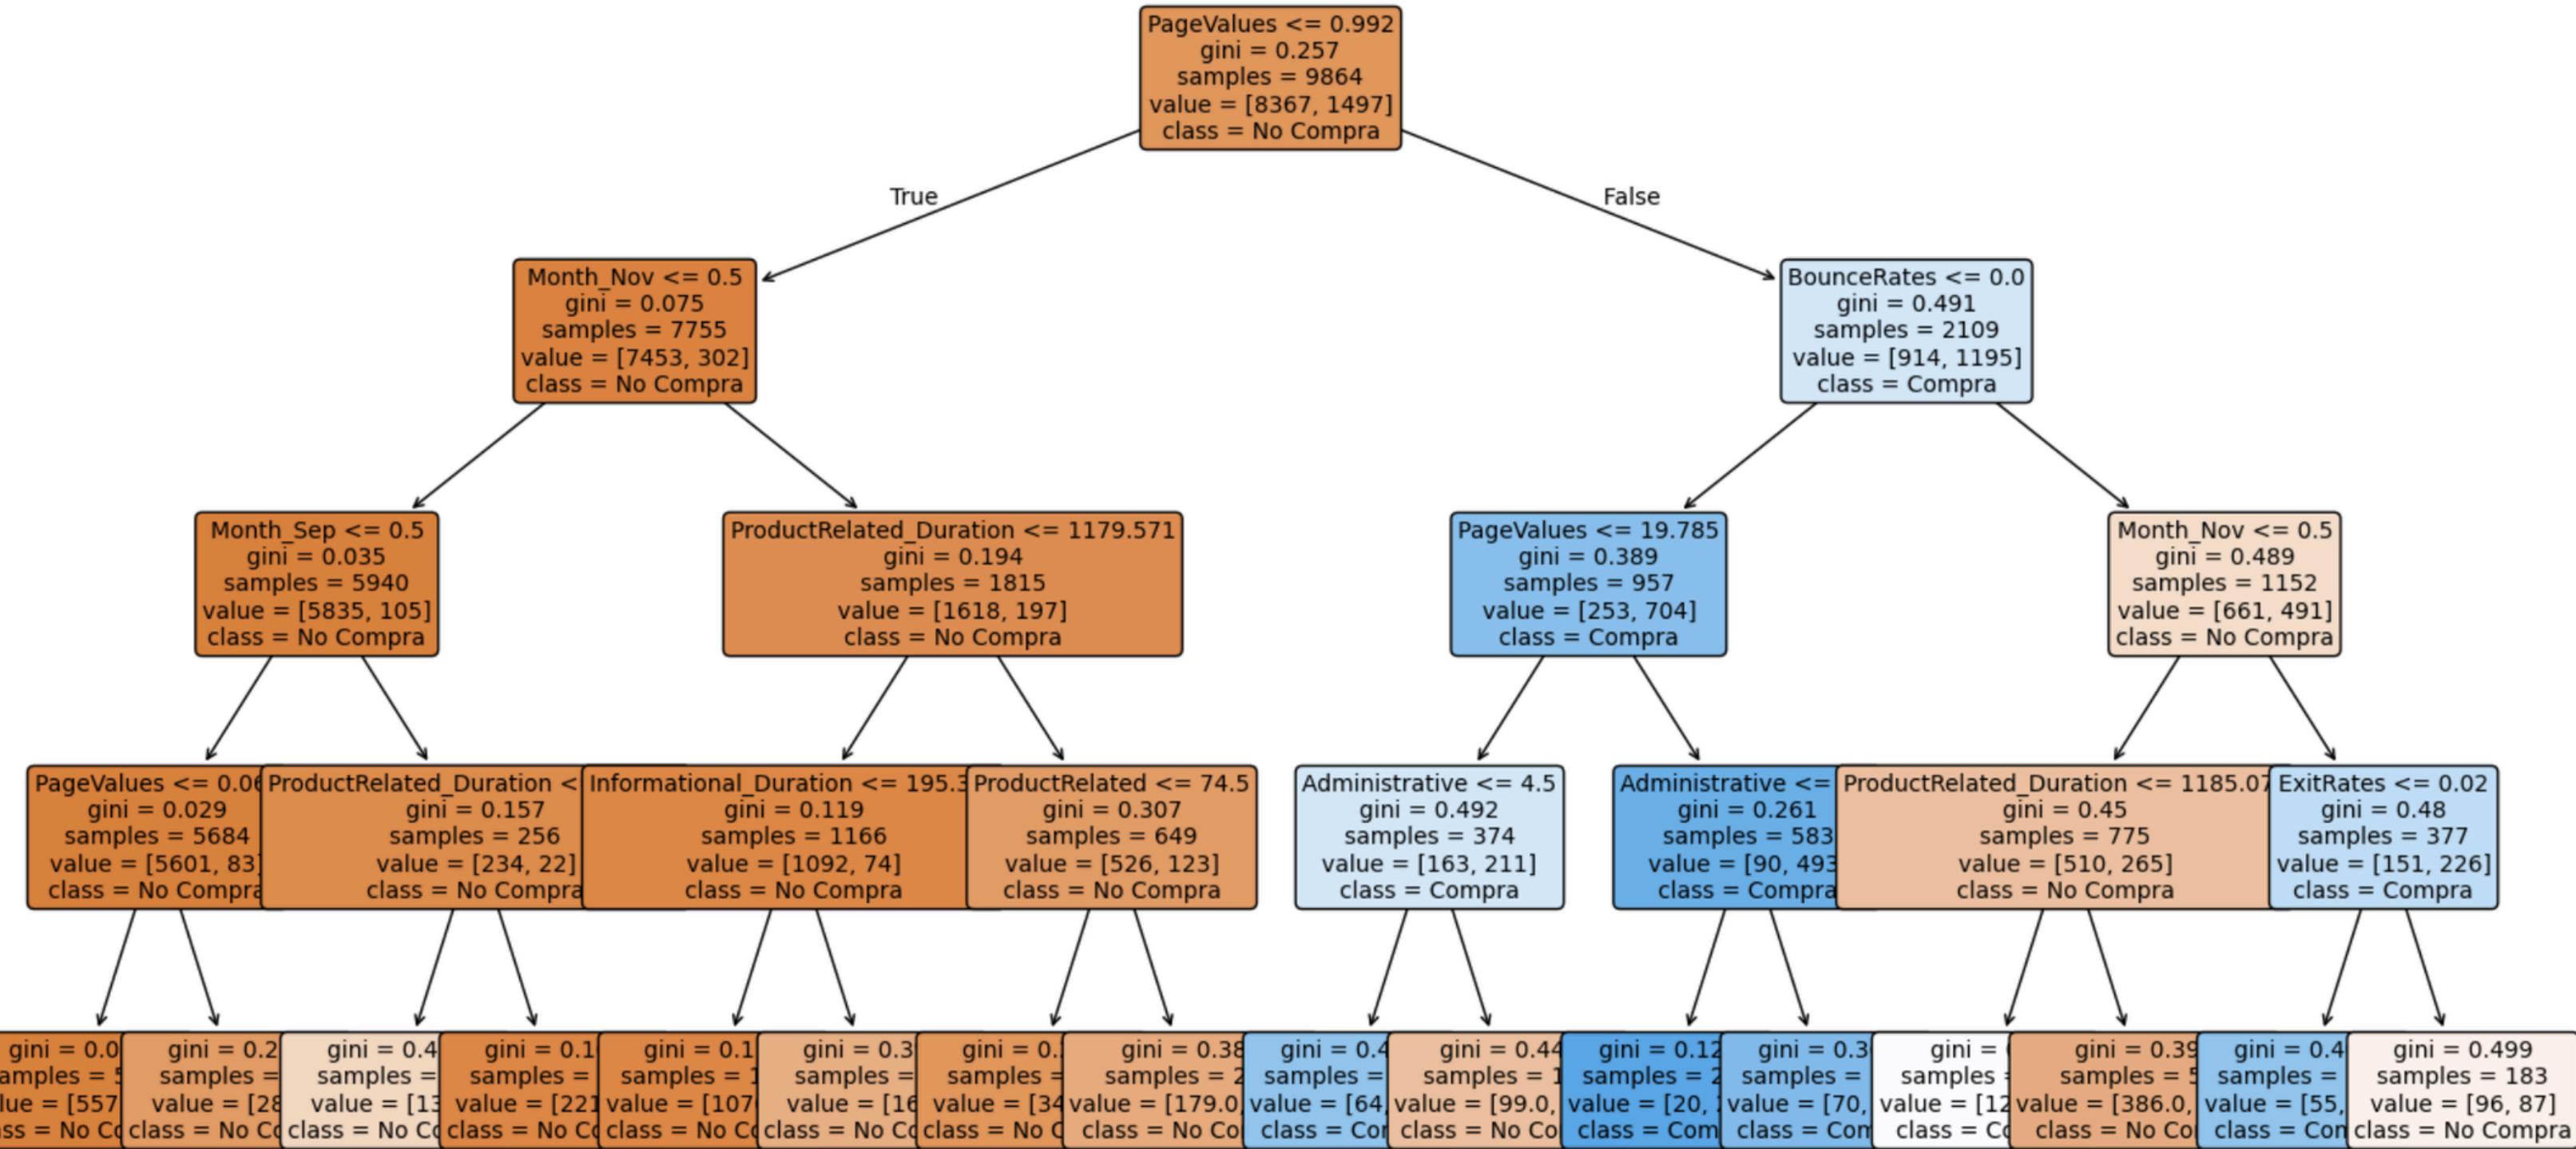


Flujo del proceso

- 1 **Carga y EDA:** Análisis de nulos y distribución de la variable objetivo (Revenue), notando un desbalance (muchos "False", pocos "True")
- 2 **Preprocesamiento:** Creación de variables dummy para datos categóricos y escalado (StandardScaler) para normalizar los datos numéricos.
- 3 **Modelado:** Entrenamiento del Árbol de Decisión y la Red Neuronal.
- 4 **Evaluación X-AI:** Visualización de la estructura del árbol (plot_tree) y cálculo de atribución de características (Gradientes Integrados) para la red.

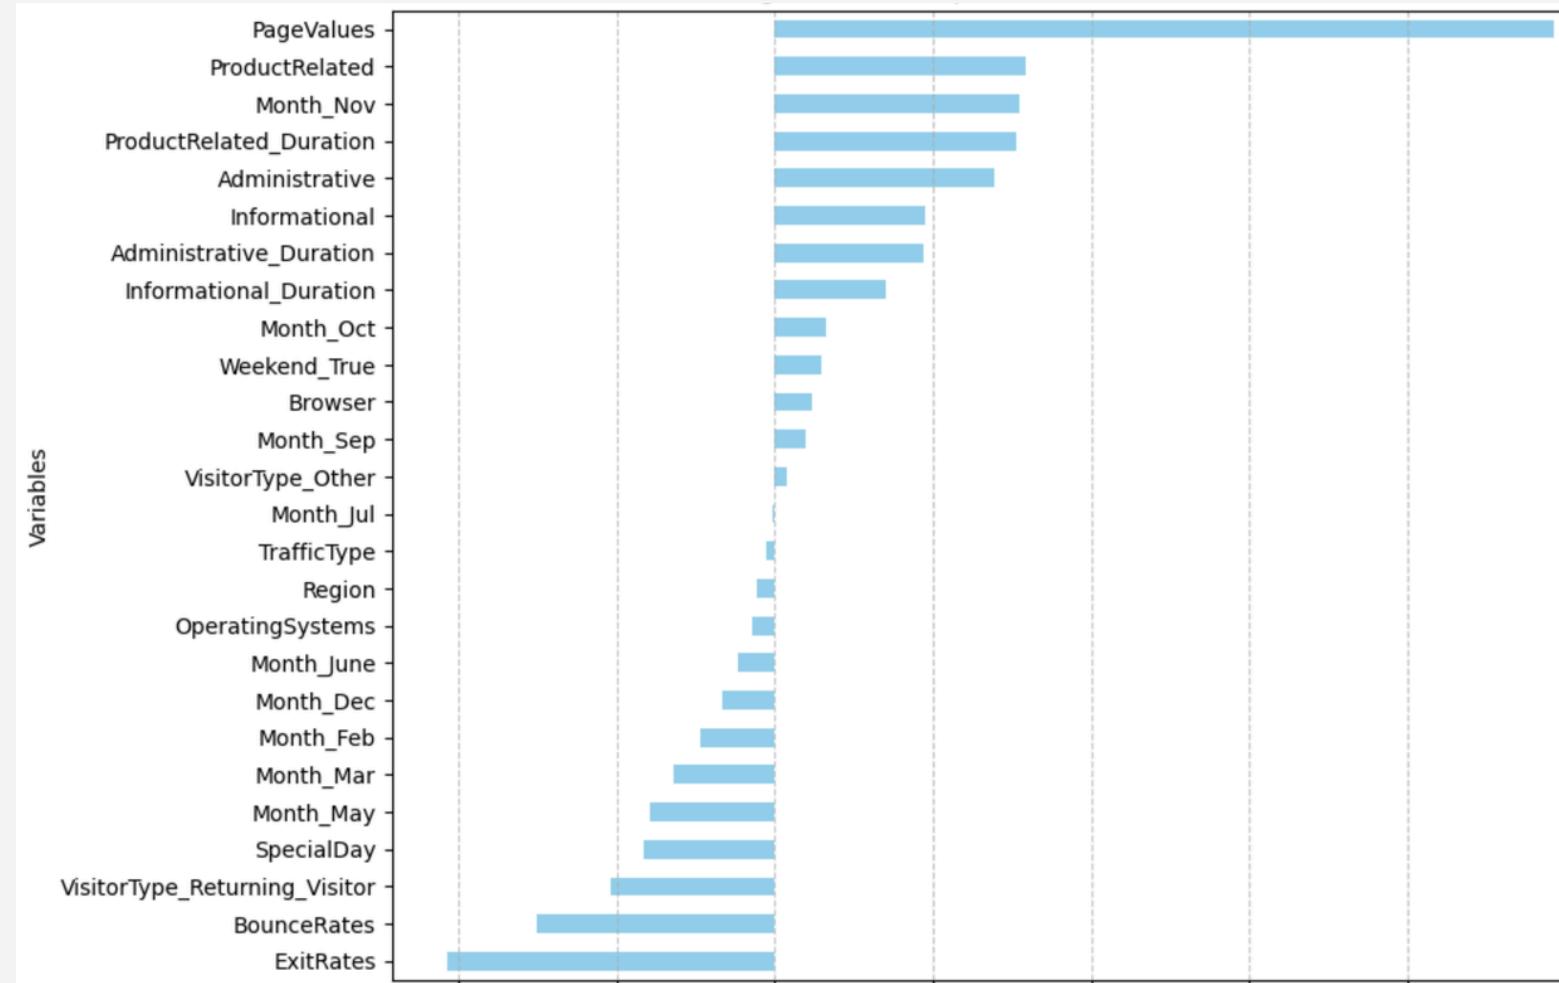


Resultados



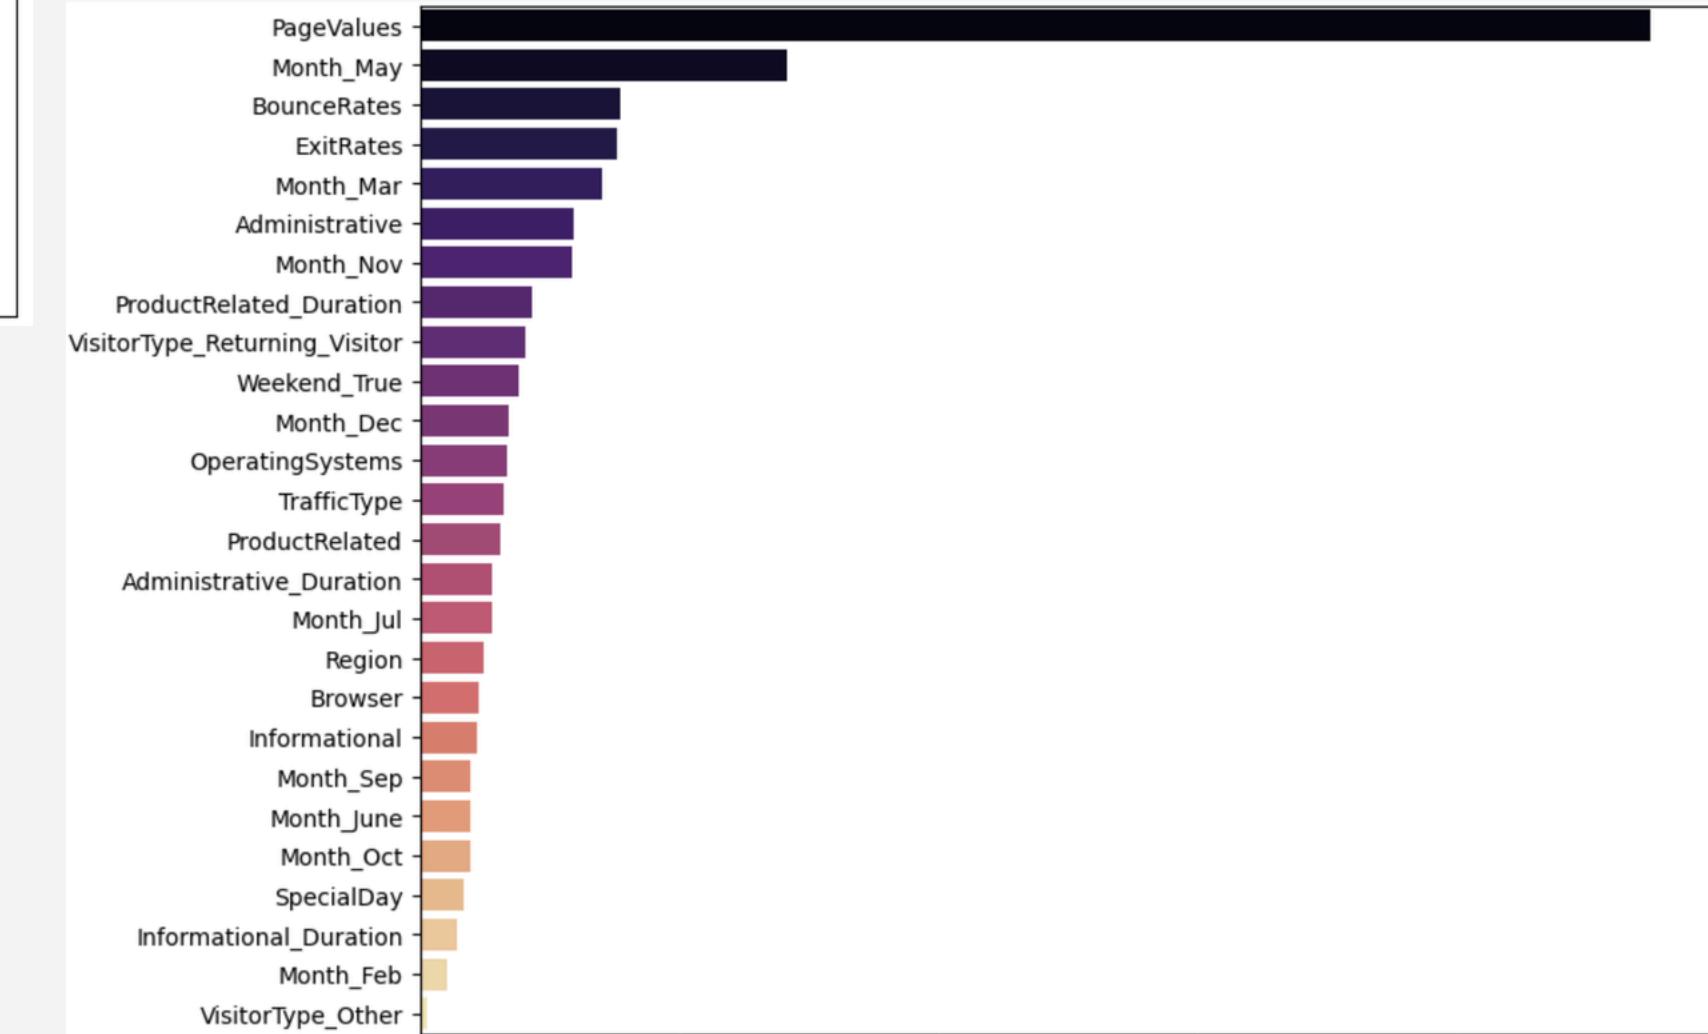


Resultados



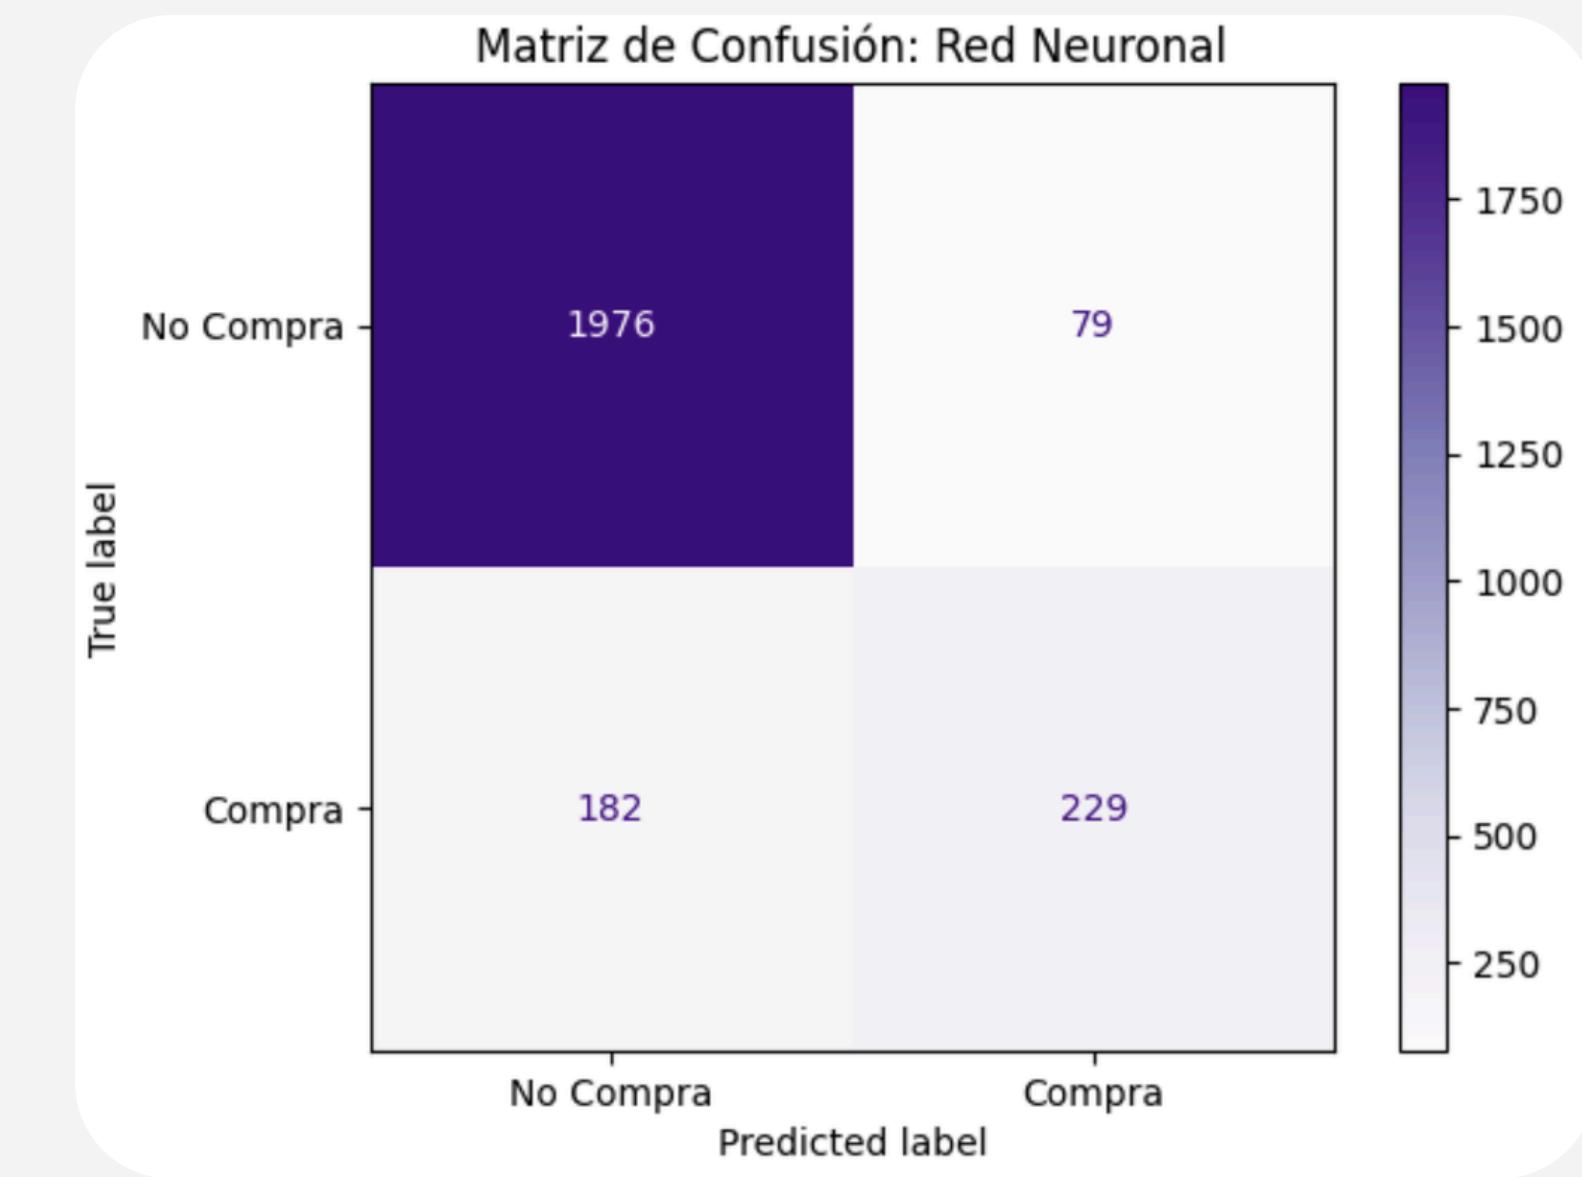
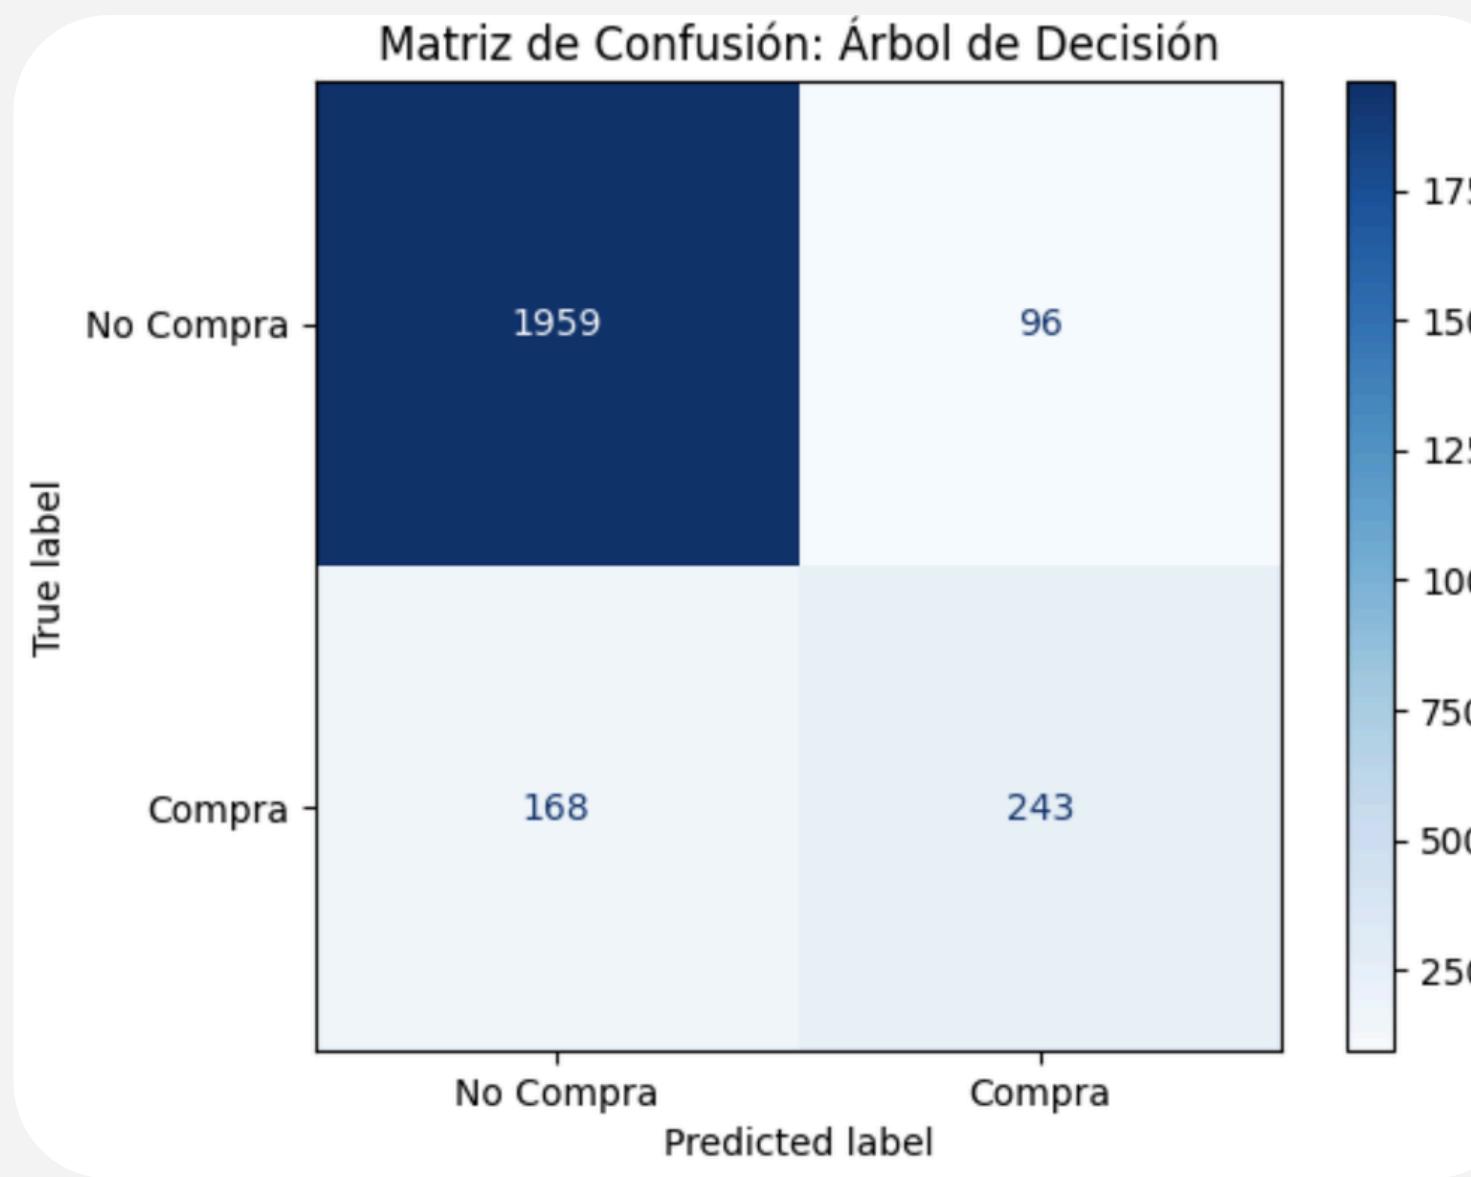
Quiere decir que el **contenido** de calidad en las páginas visitadas es **más influyente** que el tipo de sistema operativo o el tráfico de origen.

Tanto el modelo de **árboles de decisión** como el de la **red neuronal**, toman a la variable **PagesValue** como el **factor determinante**.





Resultados

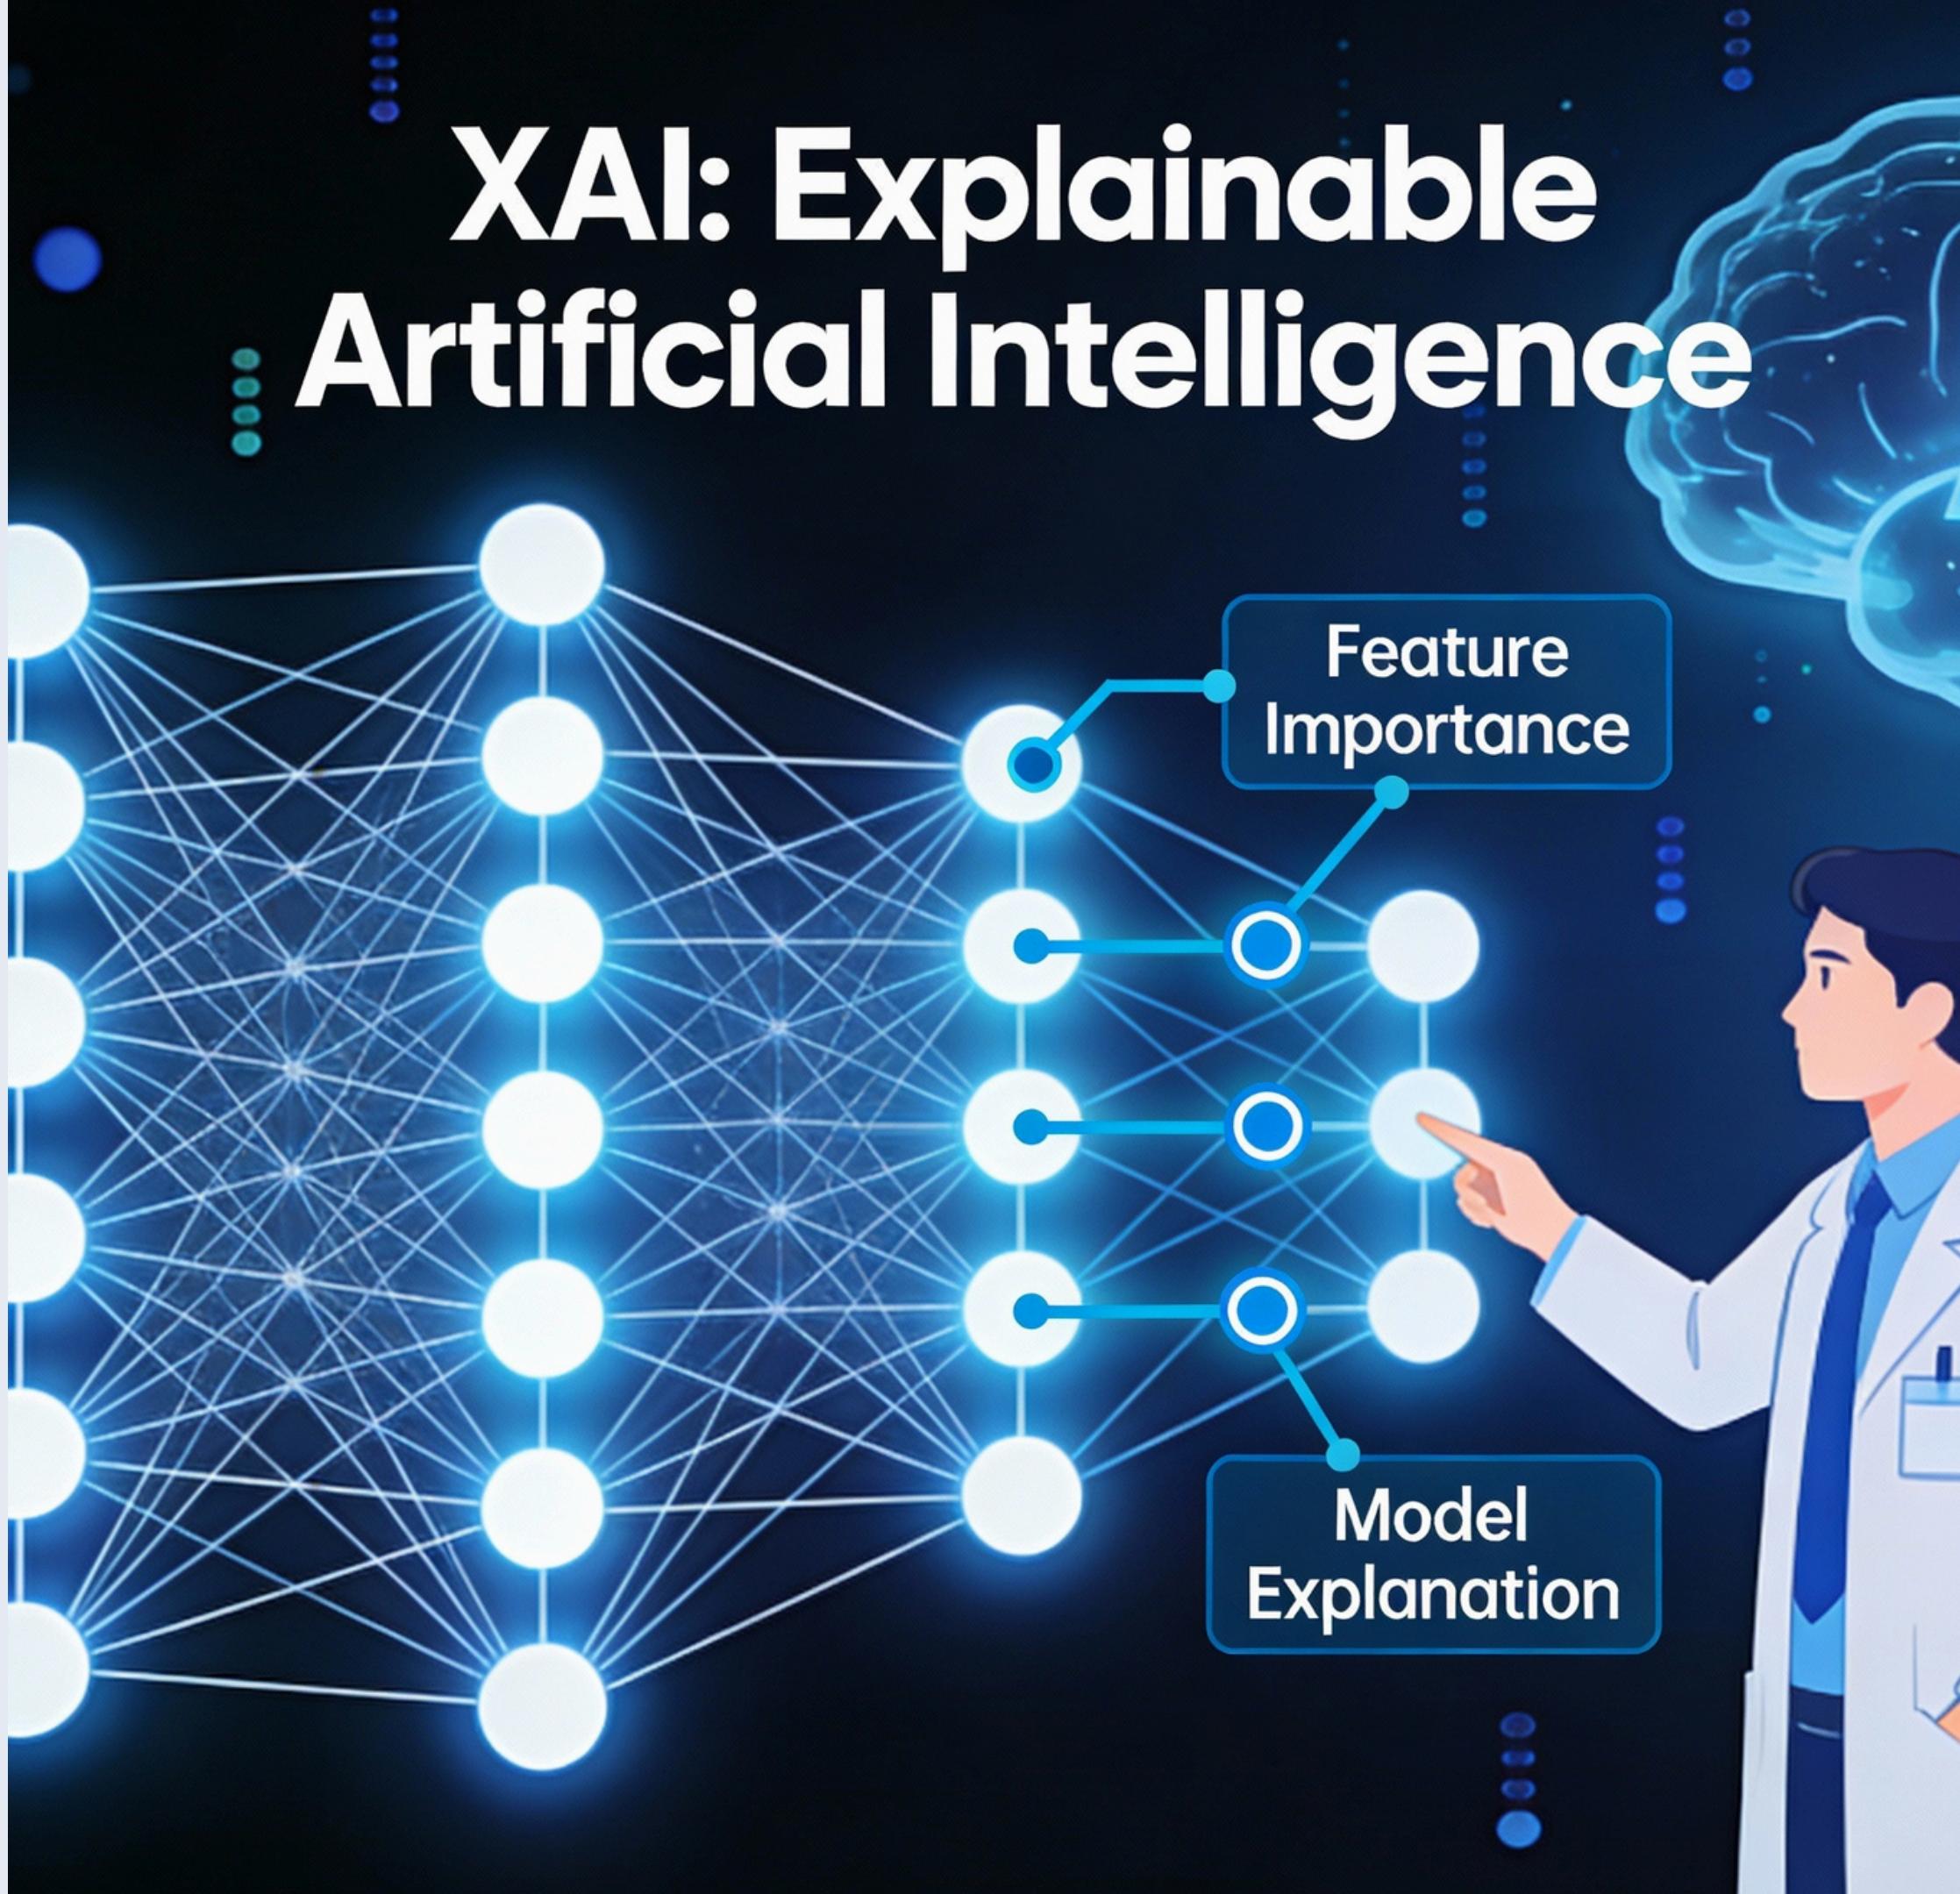


El **Árbol de Decisión** demostró ser **superior** en la detección de ingresos potenciales, minimizando los Falsos Negativos (168 vs 182)



Conclusión

El **Árbol de Decisión** demostró ser **superior** para este problema específico. Al ser el comportamiento de compra basado en "patrones lógicos y directos", el árbol capturó la decisión con **mayor precisión** en los casos de ingresos potenciales.





Modelos utilizados

CNN (Convolutional Neural Network)

Aprende automáticamente características jerárquicas

Capaz de detectar bordes, formas y patrones complejos

SVM (Support Vector Machine)

Clasificación basada en márgenes máximos

Uso de características extraídas manualmente (HOG, texturas, etc.)



Flujo del proceso

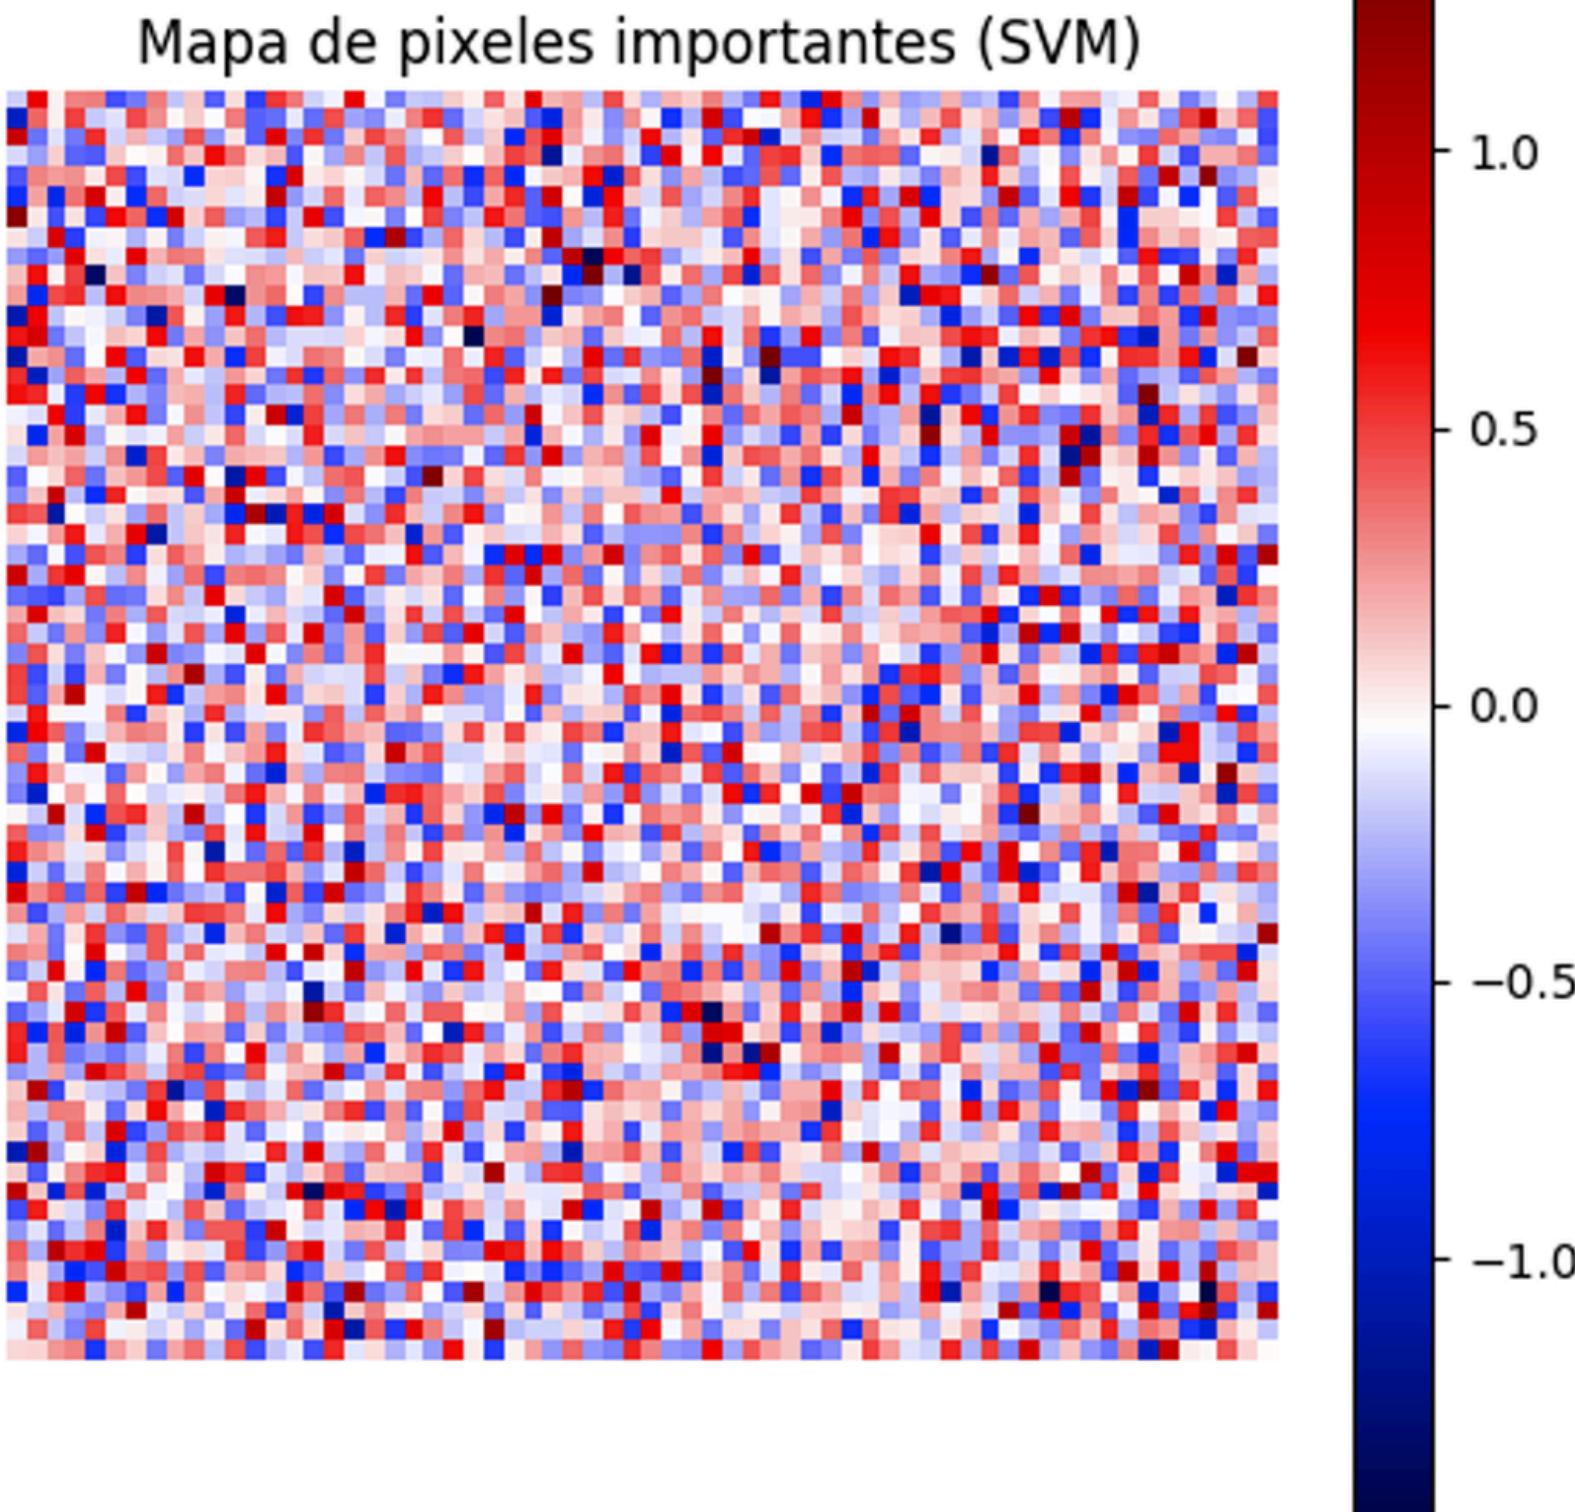
- 1 **Carga:** Lectura de imágenes y conversión a escala de grises
- 2 **Etiquetado:** Nombres de archivo con mayúscula = Gato (0), minúscula = Perro (1).
- 3 **Transformación:** Redimensionamiento a 64x64 y aplanado a un vector de 4096 valores
- 4 **Entrenamiento:** LinearSVC con 5000 iteraciones máximas.
- 5 **Visualización X-AI:** Superposición del mapa de calor de los pesos sobre la imagen original para ver qué zonas activaron la decisión.



| Modelo | Ventajas | Desventajas |
|--------|---|---|
| SVM | <ul style="list-style-type: none">• Mayor interpretabilidad.• Requiere menos datos. | <ul style="list-style-type: none">• Dependencia de la calidad de las características extraídas.• Limitado frente a alta variabilidad visual. |
| CNN | <ul style="list-style-type: none">• Alto desempeño en visión por computador.• Aprendizaje automático de características. | <ul style="list-style-type: none">• Difícil interpretación interna.• Requiere más datos y recursos computacionales. |



Resultados



La visualizacion de cada predicción se visualiza como ruido ya que las imágenes del dataset no estan alineadas, es decir que:

- El pixel (32, 18) no siempre es un ojo
- A veces es fondo, a veces cuerpo, a veces nada

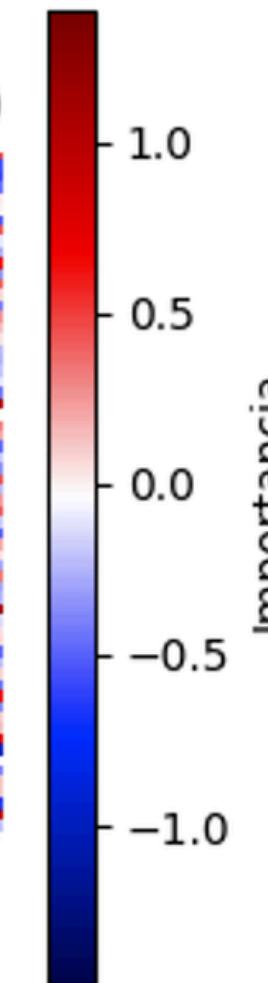
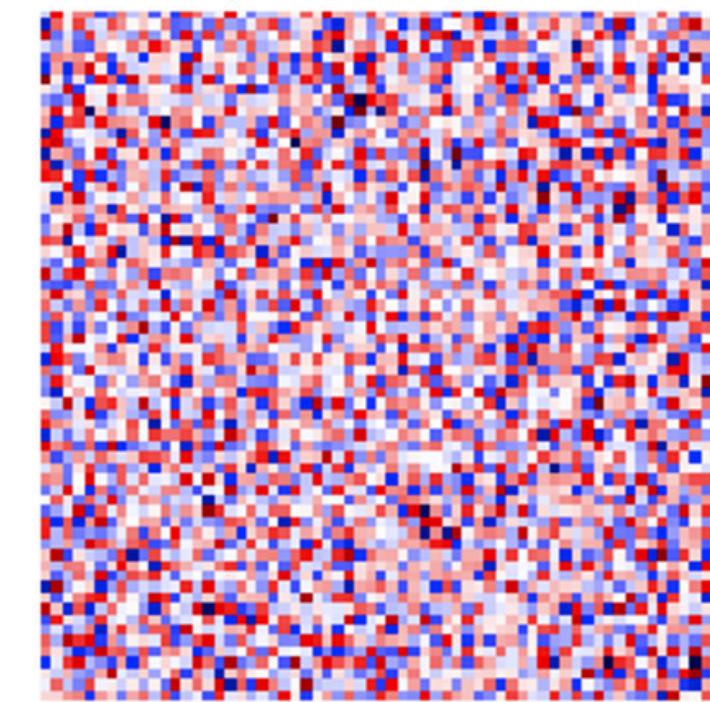


Resultados

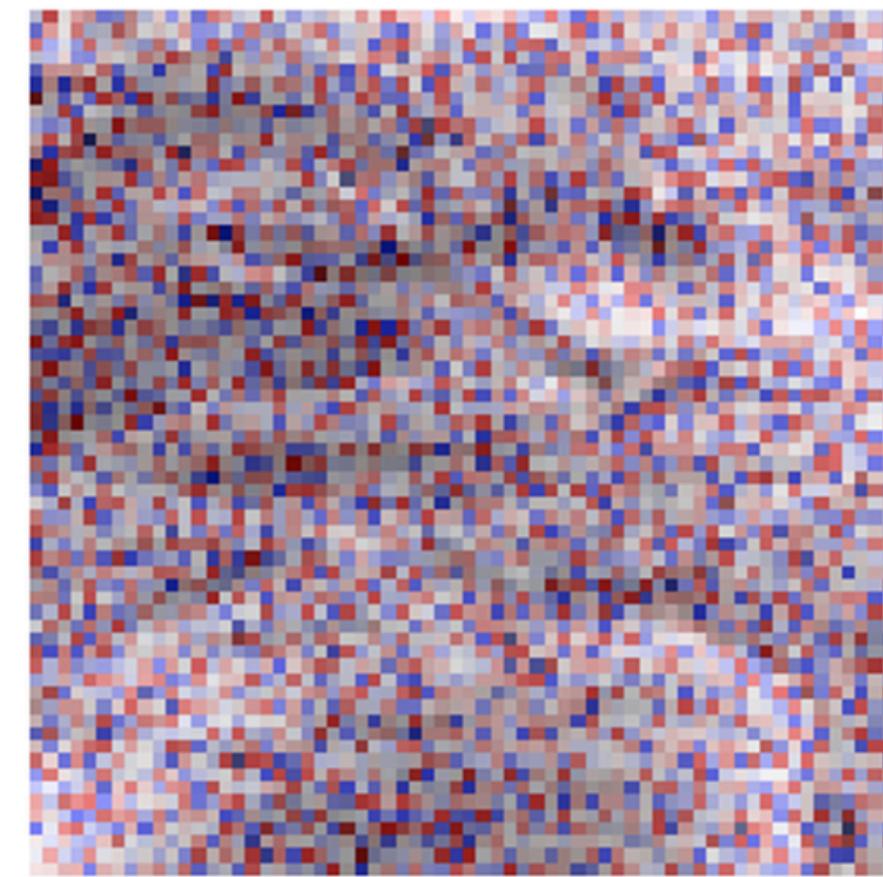


Gato | Score SVM: -1.103

Pixeles importantes (SVM)



Superposición



En este caso, los pixeles negativos (azules) son superior en cuanto a intensidad (importancia) por lo que el modelo decide que es un gato, con un margen de -1.103



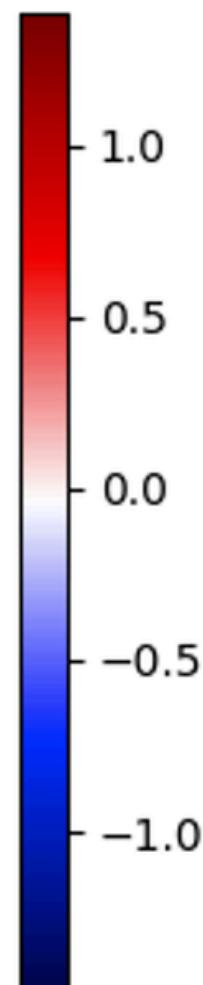
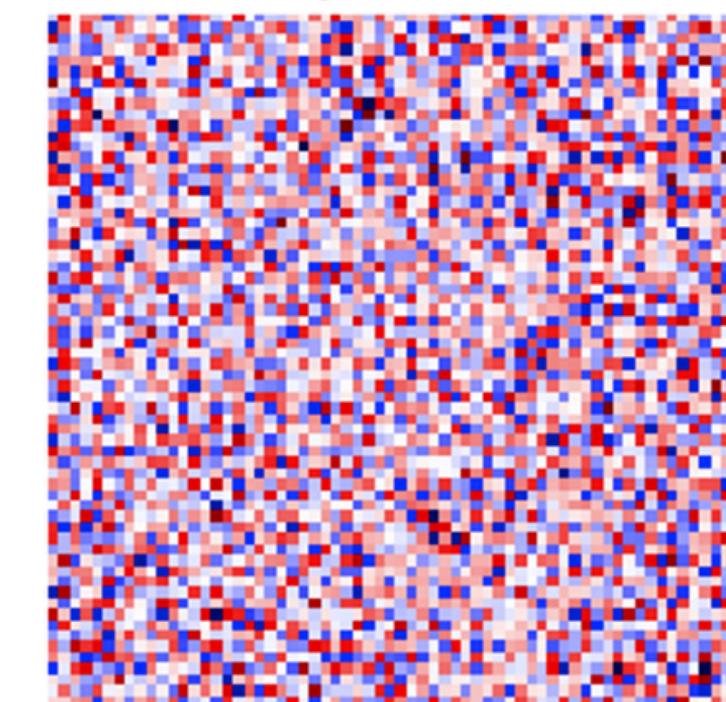
Resultados

Imagen original

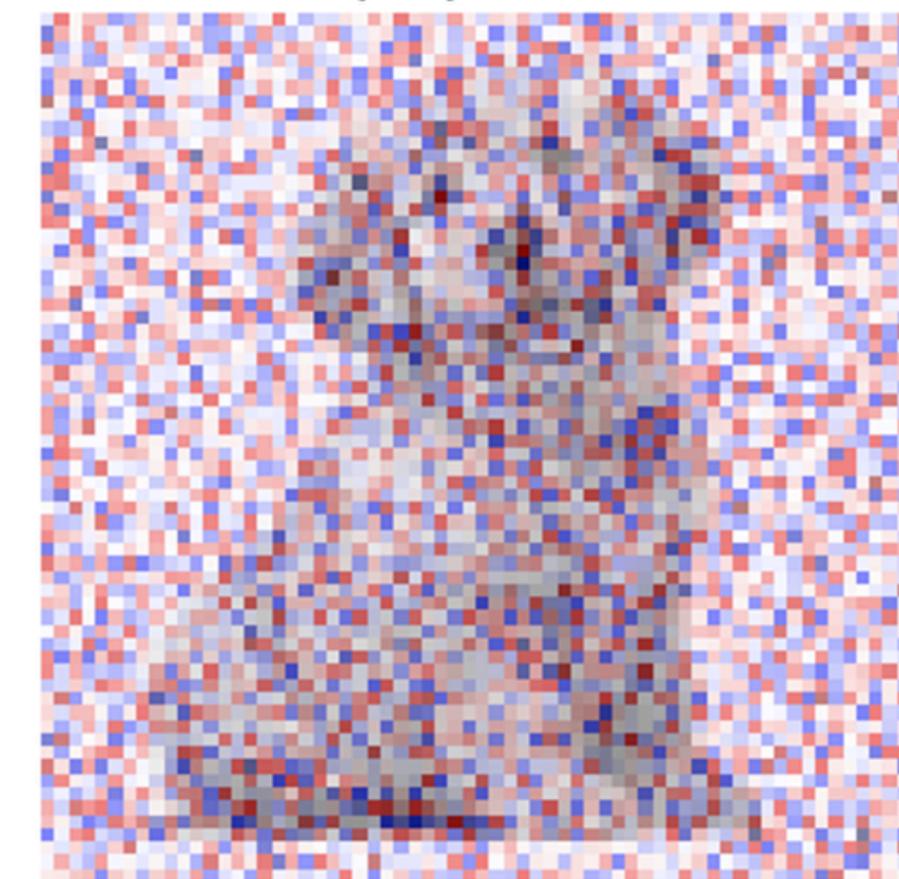


Perro | Score SVM: 2.712

Pixeles importantes (SVM)



Superposición

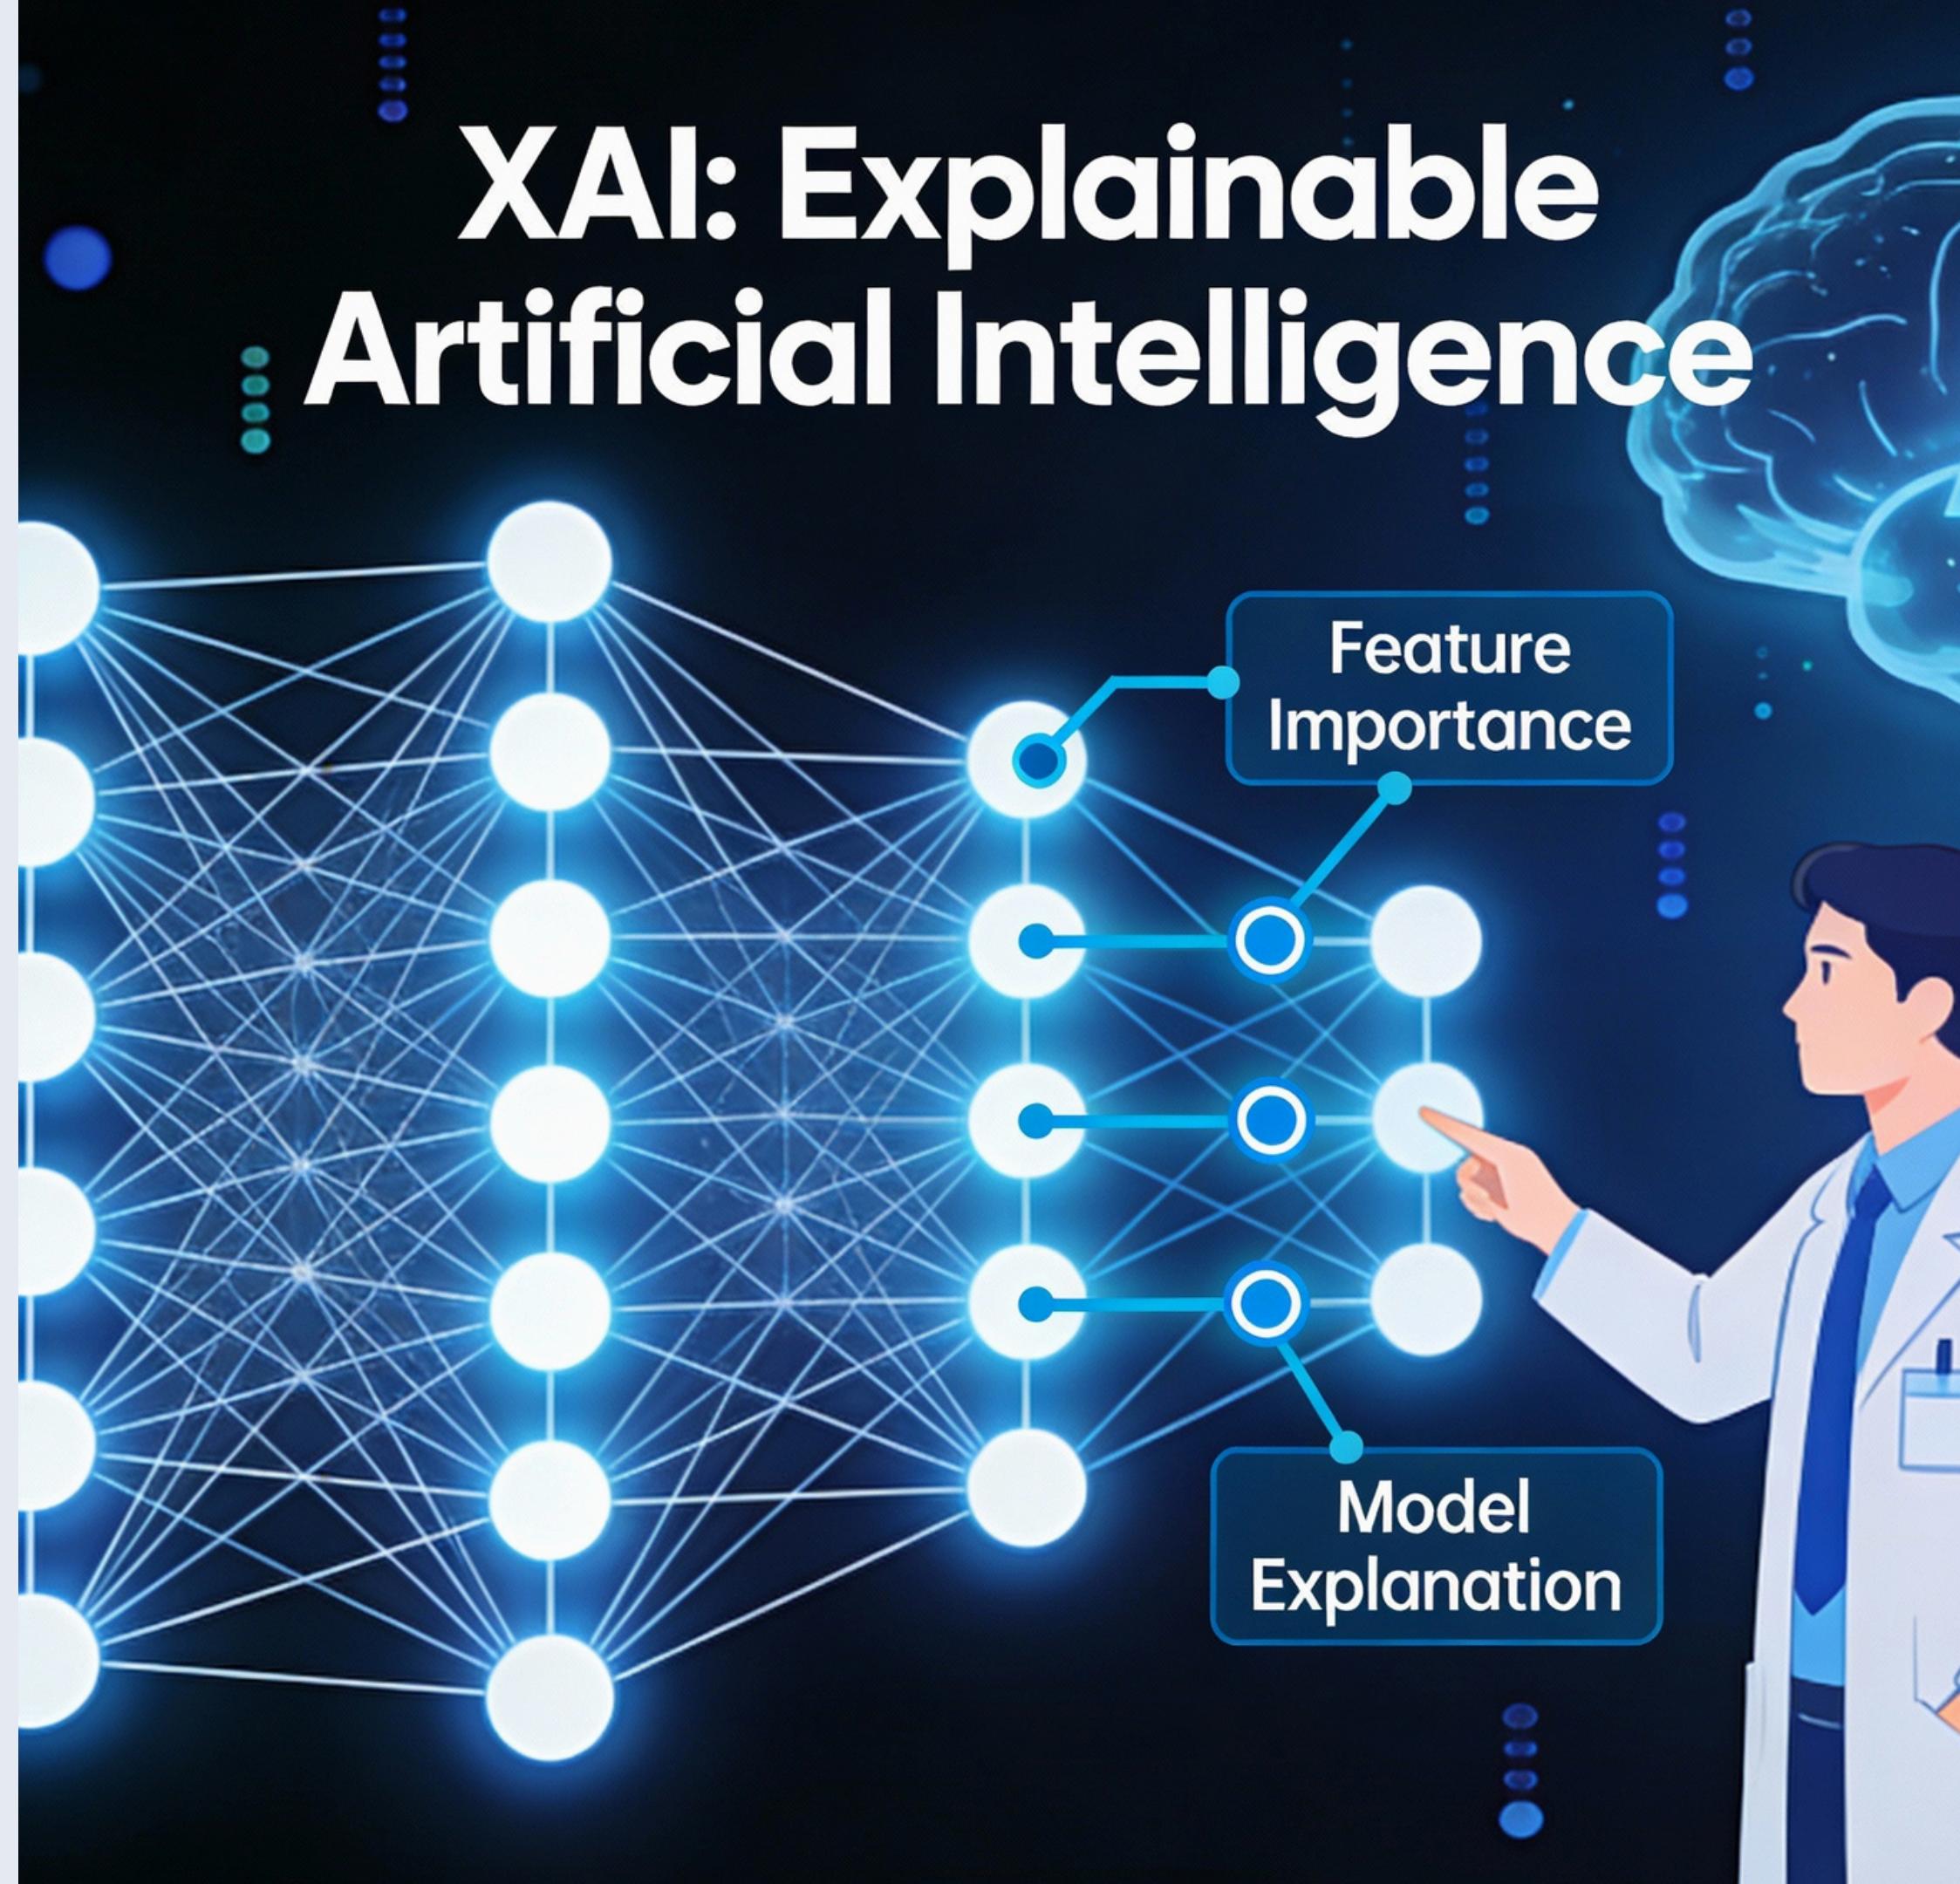


En este caso, los pixeles positivos (rojos) son superior en cuanto a intensidad (importancia) por lo que el modelo decide que es un perro, con un margen de -2.712, lo que significa que la decisión es robusta



Limitación

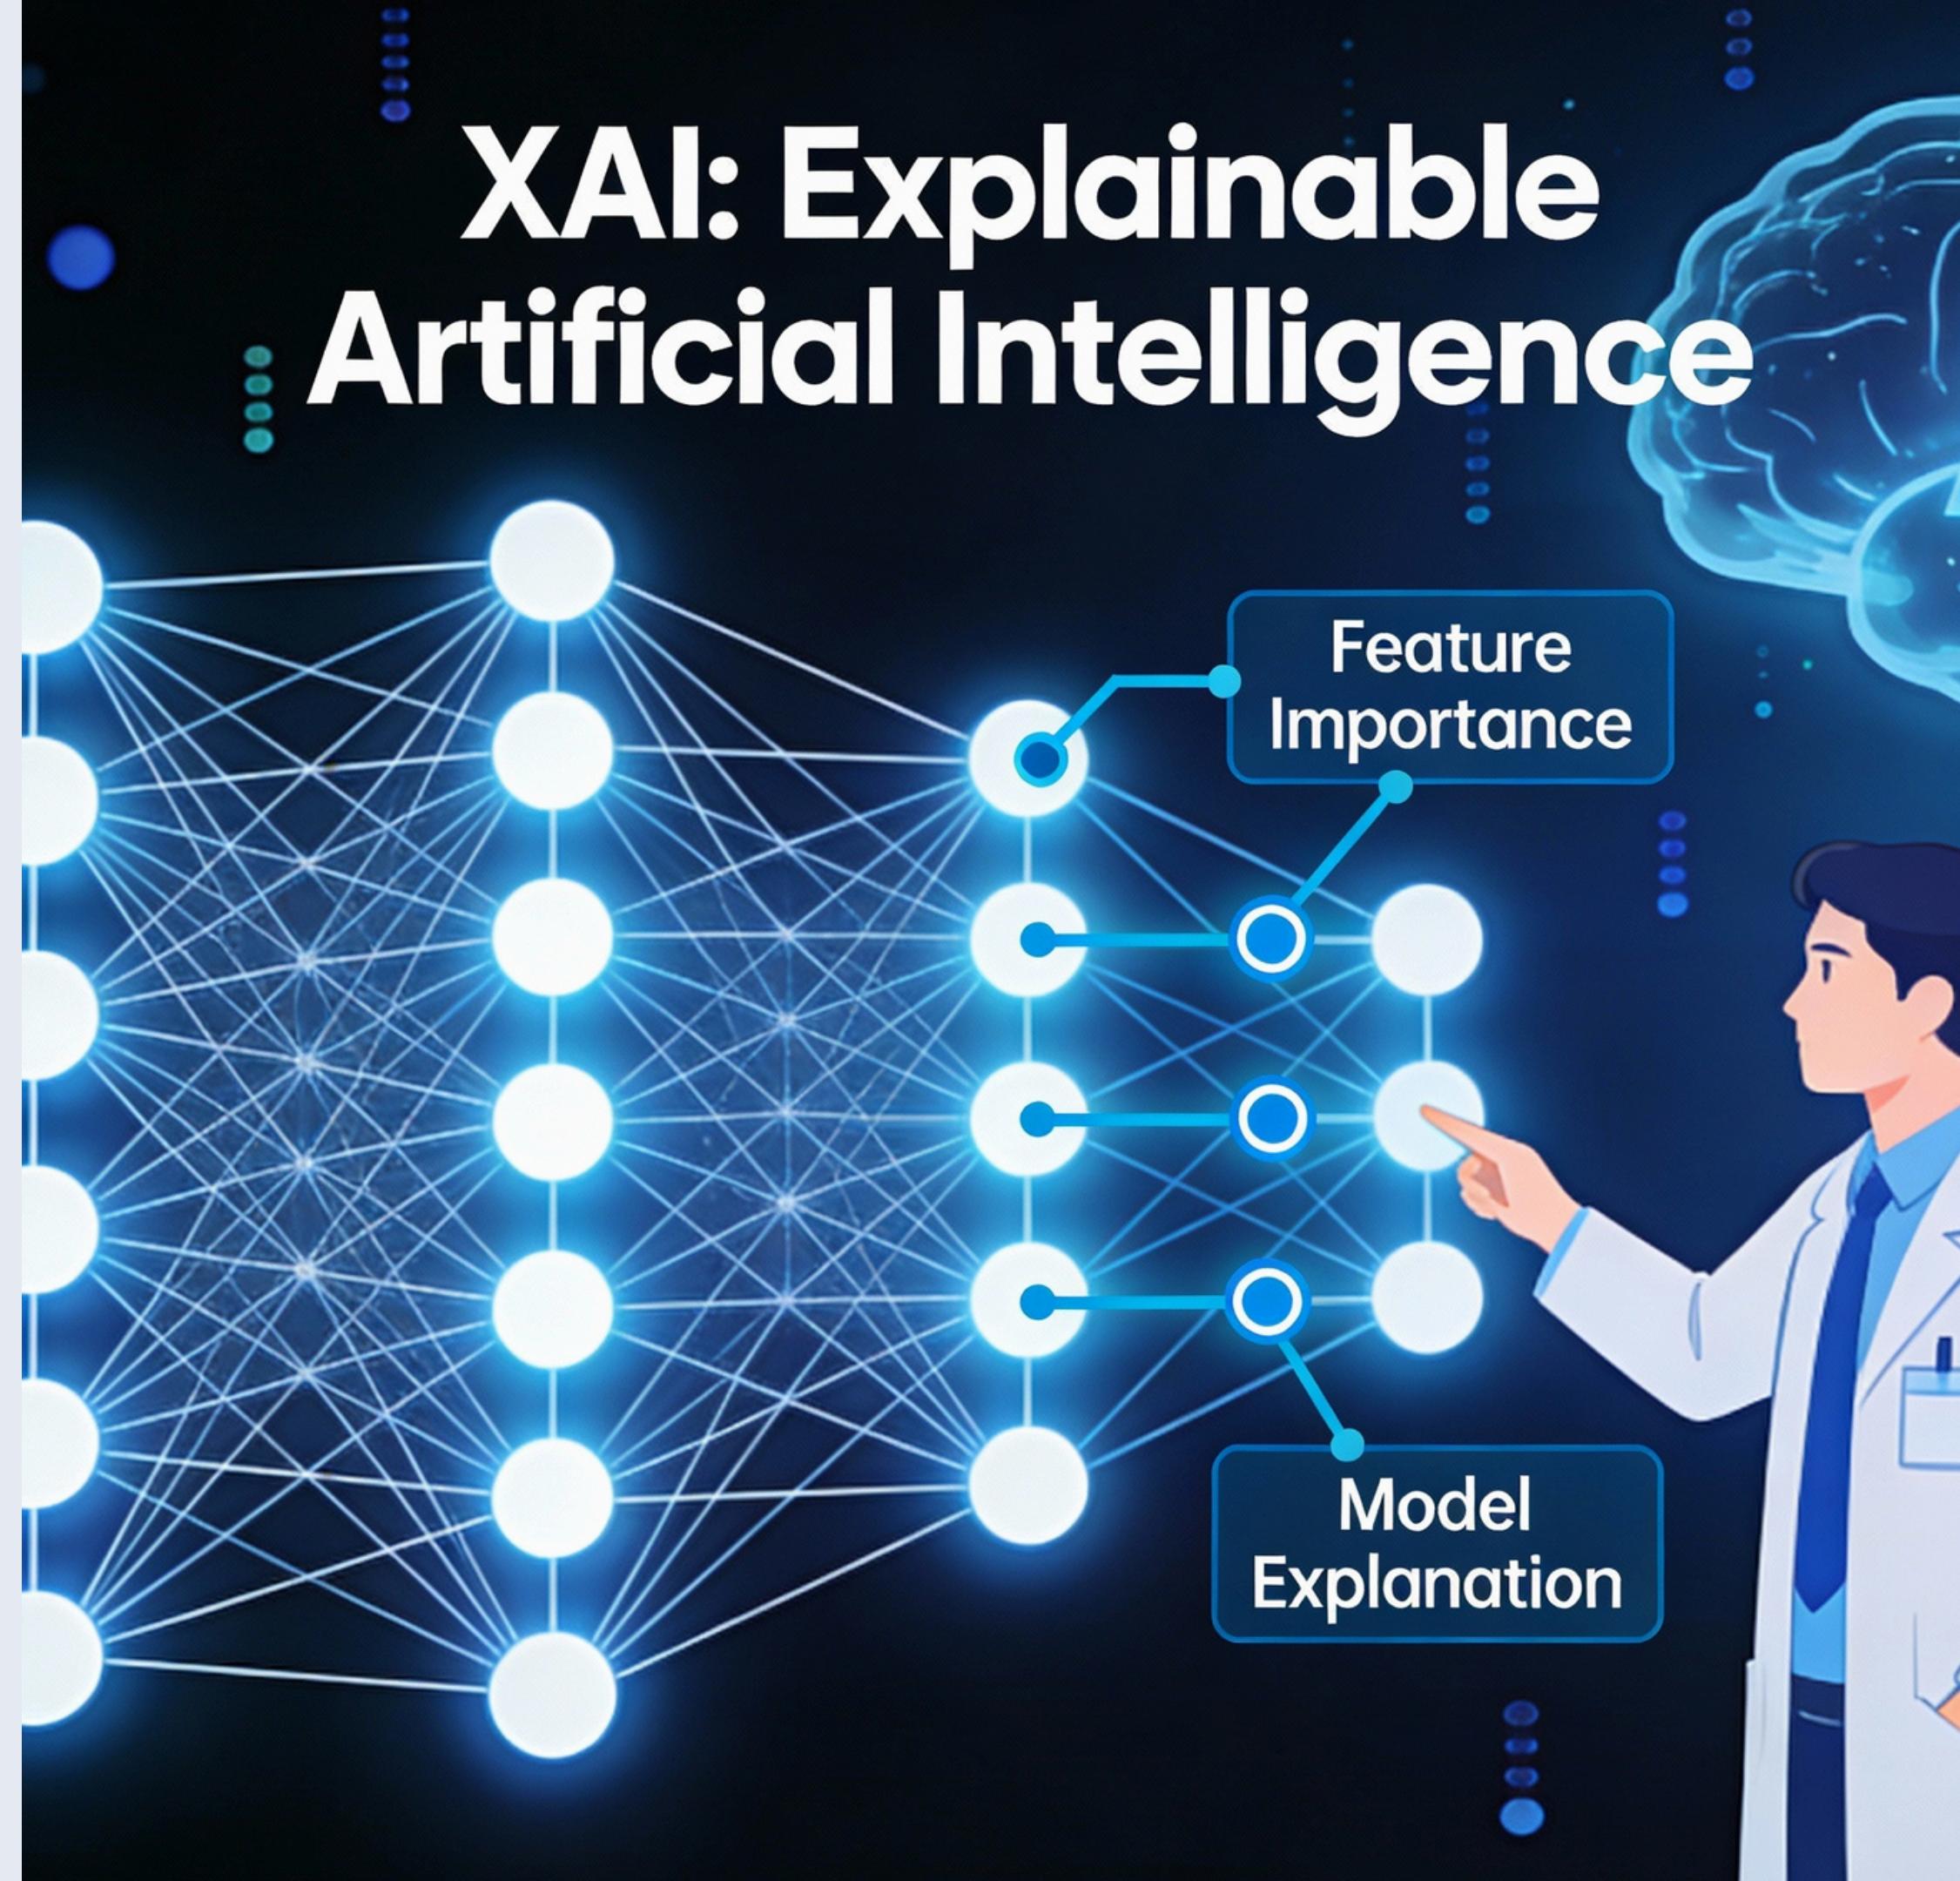
La visualización demuestra que el SVM lineal busca correlaciones espaciales fijas. Como el píxel (32, 18) a veces es fondo, a veces cuerpo y a veces nada, los pesos resultantes son dispersos y ruidosos.





Conclusión

Aunque el **SVM** ofrece **explicabilidad** matemática directa (pesos), carece de explicabilidad semántica en imágenes. Para tareas de visión, se evidencia la **necesidad** de modelos que entiendan jerarquías y estructuras como las **CNN**



Muchas Gracias



Random Forest y Red Neuronal & SVM y CNN